

İSTANBUL GEDİK ÜNİVERSİTESİ

Bilgisayar Mühendisliği Bölümü

BLM308 Veri Madenciliği Final Projesi

Raporu

Öğrenci Performans Faktörleri Sınıflandırma Analizi

Hazırlayan: Özge ÖZKUL

Öğrenci No: 231041043

GitHub Reposu: https://github.com/ozgeozkl/Veri_Madenciligi_Final_Projesi

Mayıs 2026

İçindekiler

1	Problem Tanımı, Motivasyon ve Literatür Özeti	4
1.1	Problem Tanımı	4
1.2	Motivasyon ve Proje Seçim Gerekçesi	4
1.3	Literatür Taraması ve Arka Plan	4
1.4	Projenin Hedefi ve Metodoloji (CRISP-DM)	5
2	Veri Toplama, Temizleme ve Ön İşleme	5
2.1	Veri Toplama, Hedef Değişken Seçimi ve Sınıf Dengesi	5
2.2	Veri Sözlüğü (Data Dictionary)	6
2.3	Eksik Verilerin Yönetimi ve Ölçeklendirme (Scaling)	6
2.4	Keşifçi Veri Analizi (EDA) ve Görselleştirme	7
3	Makine Öğrenmesi Model Seçimi ve Uygulama	7
3.1	Lojistik Regresyon (İstatistiksel Yaklaşım)	9
3.2	Random Forest ve GridSearchCV Optimizasyonu	9
3.3	MLP - Çok Katmanlı Sinir Ağı (Derin Öğrenme)	9
4	Değerlendirme, Performans ve Hata Analizi	9
4.1	10-Fold Cross Validation ve Performans Metrikleri	9
4.2	Hata Analizi (Confusion Matrix)	10
4.3	Bias - Variance (Önyargı - Varyans) Analizi	10
5	Sonuç ve İş Değeri Tartışması (Business Value)	11
	Yapay Zeka Kullanımı	13

Tablo Listesi

1	Student Performance Factors Veri Seti Özellikleri	6
---	---	---

Şekil Listesi

1	Veri Hazırlığı, Encoding ve Eksik Veri Doldurma Adımları	7
2	Sınıf Dağılımı (Pasta Grafiği) ve Öznitelik Korelasyon Matrisi	8
3	GridSearchCV ve 10-Fold Cross-Validation Performans Sonuçları	10
4	Lojistik Regresyon - Confusion Matrix (Hata Analizi)	11

1 Problem Tanımı, Motivasyon ve Literatür Özeti

1.1 Problem Tanımı

Çok sayıda dinamik ve karmaşık faktör, günümüzdeki eğitim sistemlerinde öğrencilerin performansını etkilemektedir. Öğrenci başarısı sadece sınıf ders saatinin etkisini içermekte değildir; birçok dış faktör (örneğin çalışma alışkanlıklarını, sosyo-ekonomik durumlarını, eğitim konusundaki aile katılımını, teknolojik erişim izni ve okuldan uzaklıklarını) akademik başarıya doğrudan etki etmektedir.

Eğitimde geleneksel yaklaşım, genellikle öğrencilerin belirlenmiş okul dönemlerindeki dönem sonu sınavları ve vizeler sonuçlanmasından sonra, "riskli" (fail veya sınıfı tekrar etme eğilimli) bir öğrencinin fark edilmesi için geçerlidir. Yani, bu yaklaşım, bir öğrencinin başarısız olması ve daha fazlasının önüne geçmek için interventif (aksiyonel) yaklaşım ile geç kalması için gereken bir "aksiyon zamanlamasına" yol açmaktadır. Bu proje ile ilgili olarak;

1.2 Motivasyon ve Proje Seçim Gerekçesi

Bu projeyi seçmemizin temel motivasyonu, Data Mining algoritmalarının ticaret, finans veya endüstri gibi alanların yanı sıra, toplumu biraz daha temel düzeyden oluşturan eğitim alanında doğrudan etkileşimler yoluyla, ölçüm yapabildiği ve insanın gerçek hayata geçecek şekilde katkısı var olan bir fayda sağlama potansiyeline sahip olmasıdır. Bir öğrencinin başarısını tesadüflere, hatta öğretmen kanaatine bırakmak yerine, verilere dayalı, tamamen objektif ve tarafsız bir mühendislik analizi yapmak hedeflenmiştir.

Geliştirilecek yüksek doğruluklu bir makine öğrenmesi modeli sayesinde, okuldaki rehberlik servisleri ve yönetim birimleri her zaman kısıtlı olan kaynaklarını (ek etüt saatleri, psikolojik danışmanlık bütçeleri, aile ile iletişim mesaisi) rastgele değil, en doğru hedeflere yönlendirebilecektir. Sınıf düşme tehlikesi yaşayan bir öğrencinin aylar öncesinden yapay zeka destekli bir model ile tespit edilmesi, hem bireysel anlamda o öğrencinin eğitim hayatını kurtaracak hem de okulun genel başarı istatistiklerini sistematik olarak yukarı taşıyacaktır.

1.3 Literatür Taraması ve Arka Plan

Literatür incelendiğinde, Eğitimsel Veri Madenciliği (Educational Data Mining - EDM) disiplininin son yıllarda ivme kazandığı görülmektedir. Erken dönem araştırmalarda öğrenci başarısını tahmin etmek için genellikle sadece "geçmiş sınav notları" veya "devamsızlık süreleri" baz alınmış ve basit doğrusal regresyon denklemleri kullanılmıştır.

Ancak modern makine öğrenmesi literatürü; öğrencinin çevresel ve sosyolojik faktörlerinin akademik başarı üzerinde en az okul içi faktörler kadar büyük bir yordayıcı (pre-

dictor) olduğunu açıkça kanıtlamıştır. Bu projede ele alınan veri seti, literatürdeki bu modern ve bütüncül yaklaşımı destekleyecek şekilde çok boyutlu demografik ve sosyolojik öznitelikler içermektedir. Literatürde sınıflandırma problemleri için Karar Ağaçları (Decision Trees), Destek Vektör Makineleri (SVM) ve Yapay Sinir Ağları (ANN) sıklıkla tercih edilmektedir. Bu projede, veri setindeki doğrusal ve karmaşık örüntüleri adil bir şekilde kıyaslayabilmek adına; istatistiksel tabanlı Lojistik Regresyon, ağaç tabanlı topluluk (ensemble) modeli Random Forest ve derin öğrenme tabanlı Çok Katmanlı Algılayıcı (MLP) algoritmaları özenle seçilmiştir.

1.4 Projenin Hedefi ve Metodoloji (CRISP-DM)

Projenin ana hedefi, öğrencileri başarılı veya riskli olarak sınıflandıracak en optimum, genellenebilir ve kararlı modelin tespit edilmesidir. Projede veri madenciliği endüstri standardı olan CRISP-DM (Cross-Industry Standard Process for Data Mining) yaşam döngüsü adım adım uygulanmıştır:

- **İş Anlayışı (Business Understanding):** Okul yönetiminin, başarısızlık riski taşıyan öğrencileri önceden tespit edecek bir erken uyarı sistemine olan ihtiyacının belirlenmesi.
- **Veri Anlayışı (Data Understanding):** Öğrenci performans verilerinin, özellik tiplerinin ve istatistiksel dağılımlarının incelenmesi; verideki potansiyel sızıntıların (data leakage) tespit edilmesi.
- **Veri Hazırlığı (Data Preparation):** Eksik (missing) verilerin Merkezi Eğilim Ölçüleri (Mod) ile doldurulması, kategorik değişkenlere One-Hot Encoding uygulanması ve sayısal verilerin ölçeklendirilmesi.
- **Modelleme (Modeling):** Sınıflandırma algoritmalarının, literatüre uygun olarak GridSearchCV hiperparametre optimizasyonu ile eğitilmesi.
- **Değerlendirme (Evaluation):** 10-Fold Cross-Validation yöntemi ile elde edilen performans metriklerinin (Accuracy, F1, ROC-AUC) çapraz analizi ve Hata Analizi (Confusion Matrix) yapılması.

2 Veri Toplama, Temizleme ve Ön İşleme

2.1 Veri Toplama, Hedef Değişken Seçimi ve Sınıf Dengesi

Çalışmada, öğrencilerin demografik bilgileri, çalışma alışkanlıkları ve aile faktörleri ile sınav başarıları arasındaki ilişkiyi inceleyen "Student Performance Factors" veri seti kullanılmıştır. Ham veri seti 6.607 satır (öğrenci kaydı) ve 20 sütundan (öznitelik) oluşmaktadır.

Makine öğrenmesi algoritmalarının regresyon yerine ikili sınıflandırma (binary classification) yapabilmesi için hedef değişken olan **Exam_Score** (Sınav Notu), verinin istatistiksel merkezi (medyanı: 67) dikkate alınarak dönüştürülmüştür. Medyan değeri olan 67 eşik kabul edilerek; notu 67 ve üzeri olan öğrenciler "1" (Başarılı), altında olan öğrenciler ise "0" (Riskli) olarak etiketlenmiş ve yepyeni bir **Target_Success** hedef sınıfı türetilmiştir.

Veri Sızıntısı (Data Leakage) Önlemi: Modelin eğitim sürecinde orijinal sınav notunu "kopya çekerek" %100 başarıya ulaşmasını (Data Leakage) engellemek amacıyla, **Exam_Score** sütunu veri setinden tamamen çıkarılmış ve algoritmaların tamamen çevresel faktörlerden öğrenmesi sağlanmıştır. Medyan üzerinden yapılan bu eşikleme sayesinde veri seti 3.725 başarılı ve 2.882 riskli öğrenci olacak şekilde mükemmel bir Sınıf Dengesi'ne (Class Balance) oturtulmuştur.

2.2 Veri Sözlüğü (Data Dictionary)

Veri setindeki temel öznitelikler, veri tipleri ve modellemedeki görevleri Tablo 1'de detaylandırılmıştır:

Tablo 1: Student Performance Factors Veri Seti Özellikleri

Öznitelik Adı	Veri Tipi	Açıklama
Target_Success	Sayısal (Hedef)	Öğrencinin başarılı (1) veya riskli (0) olma durumu.
Exam_Score	Sayısal	Orijinal sınav notu (Sızmayı önlemek için çıkarıldı).
Teacher_Quality	Kategorik	Öğretmen kalitesi algısı.
School_Type	Kategorik	Okul türü (Devlet - Public / Özel - Private).
Distance_from_Home	Kategorik	Okulun eve olan uzaklık seviyesi (Near, Moderate, Far).
Parental_Involvement	Kategorik	Ailenin eğitim sürecine katılım düzeyi (Low, Medium, High).
Hours_Studied	Sayısal	Öğrencinin haftalık ders çalışma saati.

2.3 Eksik Verilerin Yönetimi ve Ölçeklendirme (Scaling)

Veri kalitesini sağlamak adına yapılan analizde; **Teacher_Quality** ve **Parental_Education_Level** gibi bazı kategorik sütunlarda eksik (Null/NaN) değerler tespit edilmiştir. Bu satırları doğrudan silmek (Drop), o öğrenciye ait diğer sağlam ve değerli bilgilerin de kaybolmasına yol açacağından veri madenciliği prensiplerine aykırıdır. Bunun yerine, eksik veriler istatistiksel dağılımı korumak adına **Mod** (en sık tekrar eden değer) ile doldurulmuştur (Imputation).

One-Hot Encoding: Kategorik (metin tabanlı) değişkenlerin algoritmalar tarafından matematiksel olarak işlenebilmesi için One-Hot Encoding yöntemi uygulanmıştır. Dönüşüm sırasında çoklu doğrusal bağlantı (multicollinearity) sorununu ve Kukla Değişken Tuzakını (Dummy Variable Trap) önlemek için her kategorinin ilk sütunu düşürülmüştür (**drop_first=True**).

Standardizasyon (StandardScaler): Özellikle Çok Katmanlı Sinir Ağları (MLP) ve gradient-descent tabanlı Lojistik Regresyon modelleri, farklı ölçeklerdeki sayısal verilerden (örneğin haftalık uyku saati ile aile geliri arasındaki büyük sayısal farklardan) olumsuz etkilenmektedir. Bu nedenle, tüm bağımsız değişkenlere Standartlaştırma uygulanmış, tüm değerlerin ortalaması 0, standart sapması 1 olacak şekilde aynı matematiksel düzleme çekilmesi sağlanmıştır.

```
Temizlenmiş veri yükleniyor...
Metin içeren şu sütunlar 0 ve 1'lere
dönüştürülüyor:
- Parental_Involvement
- Access_to_Resources
- Extracurricular_Activities
- Motivation_Level
- Internet_Access
- Family_Income
- Teacher_Quality
- School_Type
- Peer_Influence
- Learning_Disabilities
- Parental_Education_Level
- Distance_from_Home
- Gender

--- İŞLEM SONUCU ---
Eski Sütun Sayısı: 20
Yeni Sütun Sayısı: 28
```

Şekil 1: Veri Hazırlığı, Encoding ve Eksik Veri Doldurma Adımları

2.4 Keşifçi Veri Analizi (EDA) ve Görselleştirme


Makine öğrenmesi modelleri kurulmadan önce veri setindeki gizli örüntüleri, sınıf dağılımlarını ve öznitelikler arası ilişkileri anlamak amacıyla kapsamlı bir Keşifçi Veri Analizi (EDA) gerçekleştirilmiştir. Şekil 2’da yer alan pasta grafiğinde, **Target_Success** hedef değişkenimizin dağılımının oldukça dengeli olduğu teyit edilmiştir (Sınıf dengesizliği/Imbalance problemi yoktur).

Ayrıca, sayısal öznitelikler arasında oluşturulan **Korelasyon Matrisi (Isı Haritası)** sayesinde, bağımsız değişkenlerin hem birbirleriyle hem de hedef değişkenle olan ilişkileri (Pearson Korelasyon Katsayıları) incelenmiştir. Matris incelendiğinde, özellikler arasında modele zarar verecek seviyede yüksek bir korelasyon (multicollinearity) saptanmamış, verilerin birbirinden bağımsız ve temiz bilgiler sunduğu görülmüştür.

3 Makine Öğrenmesi Model Seçimi ve Uygulama

No Free Lunch (Bedava Öğle Yemeği Yok) teoremi gereği, tek bir algoritmanın her veri setinde en iyi sonucu vereceğinin bir garantisi yoktur. Bu nedenle verideki farklı (doğrusal

Öğrenci Başarı Durumu Dağılımı



Öznitelikler Arası Korelasyon Matrisi

Hours_Studied	1.00	-0.01	0.01	0.02	-0.01	0.00
Attendance	-0.01	1.00	-0.02	-0.02	0.01	-0.02
Sleep_Hours	0.01	-0.02	1.00	-0.02	-0.01	-0.00
Previous_Scores	0.02	-0.02	-0.02	1.00	-0.01	-0.01
Tutoring_Sessions	-0.01	0.01	-0.01	-0.01	1.00	0.02

ve doğrusal olmayan) örüntüleri yakalamak için üç farklı aileden algoritmalar kurgulanmıştır.

3.1 Lojistik Regresyon (İstatistiksel Yaklaşım)

Girdi değişkenleri ile hedef sınıf arasındaki doğrusal ilişkileri Sigmoid fonksiyonu yardımıyla modellemek için kurulmuştur. Özellikler arasındaki matematiksel ağırlıkları (katsayıları) hesaplayarak 0 ile 1 arasında bir olasılık değeri (risk skoru) üretir. Parametre optimizasyonu sırasında modelin daha dengeli yakınsaması (convergence) için maksimum iterasyon sayısı 1000 olarak belirlenmiştir.

3.2 Random Forest ve GridSearchCV Optimizasyonu

Random Forest, birden fazla karar ağacının (Decision Tree) bir araya gelerek çoğunluk oylaması (majority voting / bagging) yaptığı güçlü bir topluluk (ensemble) algoritmasıdır. Verideki karmaşık, doğrusal olmayan örüntüleri yakalamada oldukça başarılıdır.

Hiperparametre Optimizasyonu: Algoritmanın varsayılan (default) ayarlarla bırakılması, veri setine ezberlemesine (overfitting) veya eksik öğrenmesine yol açabilir. Bu riski ortadan kaldırmak için Scikit-Learn kütüphanesinin **GridSearchCV** modülü kullanılmıştır. 5-Fold Cross Validation (Çapraz Doğrulama) eşliğinde, **n_estimators** (ağaç sayısı) ve **max_depth** (maksimum derinlik) parametreleri için bir arama uzayı taranmıştır. Yapılan Grid Search sonucunda, modelin karmaşıklığını dengeleyen en optimum parametre seti bulunmuş ve nihai yarışmaya bu "Optimize Edilmiş" model sokulmuştur.

3.3 MLP - Çok Katmanlı Sinir Ağı (Derin Öğrenme)

İnsan beyninin biyolojik nöron yapısından esinlenen Multi-Layer Perceptron (MLP) modeli, girdi ve çıktı katmanları arasına yerleştirilmiş gizli katmanlar (hidden layers) aracılığıyla çalışır. Modelin eğitim kapasitesini artırmak için gizli katmandaki nöron sayısı 50 (**hidden_layer_sizes=(50,)**) olarak belirlenmiş ve geriye yayılım (backpropagation) algoritmalarının verideki karmaşık ilişkileri çözmesi amaçlanmıştır.

4 Değerlendirme, Performans ve Hata Analizi

4.1 10-Fold Cross Validation ve Performans Metrikleri

Modellerin performansını tek bir rastgele eğitim-test ayırımına (train-test split) güvenerek ölçmek, şans faktörünü işin içine katacağı için bilimsel olarak yeterli değildir. Bu nedenle endüstri standardı olan **10-Fold Cross-Validation** (10 Katlı Çapraz Doğrulama) yöntemi uygulanmıştır. Veri seti 10 eşit parçaya bölünmüş, algoritmalar 9 parça ile eğitilip

1 parça ile test edilmiş ve bu işlem sırayla 10 kez tekrarlanmıştır. Modellerin başarısı şu metriklerle ölçülmüştür:

- **Accuracy (Doğruluk):** Modelin doğru sınıflandırdığı toplam öğrenci sayısının, tüm öğrencilere oranıdır.
- **F1-Skoru:** Kesinlik (Precision) ve Duyarlılık (Recall) değerlerinin harmonik ortalamasıdır. Sınıflar arası olası bir dengesizlikte modelin gerçek başarısını gösterir.
- **ROC-AUC:** Modelin başarılı bir öğrenci ile riskli bir öğrenciyi birbirinden doğru şekilde ayırt edebilme kapasitesidir (1'e ne kadar yakınsa o kadar mükemmeldir).

```
-----  
--  
🏆 Model: Lojistik Regresyon  
Doğruluk (Accuracy) : %98.03  
F1-Skoru           : %98.26  
ROC-AUC            : %99.51  
-----  
--  
🏆 Model: Random Forest (Rastgele Orman)  
Doğruluk (Accuracy) : %89.90  
F1-Skoru           : %91.11  
ROC-AUC            : %96.64  
-----
```

Şekil 3: GridSearchCV ve 10-Fold Cross-Validation Performans Sonuçları

Çıktılar incelendiğinde; Lojistik Regresyon %98.03 Doğruluk, %98.26 F1-Skoru ve %99.51 ROC-AUC değeri ile hem Sinir Ağlarını (MLP) hem de Random Forest modelini geride bırakarak **Şampiyon Model** olmuştur.


4.2 Hata Analizi (Confusion Matrix)

Performansı en yüksek model olan Lojistik Regresyon'un gerçek hayatta yaptığı tahmin hatalarının yönünü ve ağırlığını detaylıca tespit etmek için Karmaşıklık Matrisi (Confusion Matrix) çizdirilmiştir. Bir erken uyarı sisteminde sadece "Doğruluk" yeterli değildir; modelin kaç tane riskli öğrenciyi gözden kaçırdığı (False Negative) hayati önem taşır.

Şekil 4'de görülen Confusion Matrix incelendiğinde, modelin hem Başarılı (1) hem de Riskli (0) sınıfları yüksek isabet oranıyla bulduğu (köşegen üzerindeki True Positive ve True Negative değerlerinin büyüklüğü), yanlış alarm veya gözden kaçırma hatalarının ise toplam veri seti içinde marjinal bir seviyede kaldığı kanıtlanmıştır.

4.3 Bias - Variance (Önyargı - Varyans) Analizi

Elde edilen sonuçlar makine öğrenmesinin temel problemi olan Bias-Variance İkilemi (Tradeoff) çerçevesinde incelendiğinde oldukça ilginç bir akademik tablo ortaya çıkmaktadır.



Şekil 4: Lojistik Regresyon - Confusion Matrix (Hata Analizi)

Görece çok daha karmaşık ve derin bir ağaç (ensemble) modeli olan Random Forest (%89.90 Doğruluk), esnek yapısı gereği veri setindeki küçük dalgalanmaları ve gürültüleri ezberlemeye (Overfitting - **Yüksek Varyans / High Variance**) meyilli bir algoritmadır. Veri setimizde hedef ile girdiler arasında güçlü ve net kurallar olduğu için, Random Forest bu kuralları dallara bölerken veri setini gereğinden fazla karmaşıklaştırmış ve performans kaybı yaşamıştır.

Buna karşın Lojistik Regresyon, yapısal olarak "katı" ve **Yüksek Önyargı (High Bias)** barındıran basit, doğrusal (linear) bir modeldir. Genellikle karmaşık verilerde yetersiz kalması beklenirken, bu projede verinin özündeki doğrusal ilişkiler (çalışma saati arttıkça başarımın artması vb.) Lojistik Regresyon'un temel matematiği ile tam olarak örtüştüğü (perfect fit) için model muazzam bir başarı elde etmiş ve %98 sınırını aşmıştır.

5 Sonuç ve İş Değeri Tartışması (Business Value)

Bu çalışmada, öğrencilerin çevresel, sosyolojik ve demografik verileri kullanılarak akademik risk durumlarını önceden tahmin edebilen makine öğrenmesi modelleri kurgulanmıştır. Süreç boyunca CRISP-DM metodolojisinin adımları eksiksiz izlenmiş, veri sızıntısı engellenmiş, GridSearchCV ile optimizasyon yapılmış ve Lojistik Regresyon algoritmasının mükemmeye yakın (%98) performans sergilediği kanıtlanmıştır.

Sistemin Okullara Sağlayacağı İş Değeri: Geliştirilen bu "Şampiyon" erken uyarı

sisteminin okul altyapılarına entegre edilmesi, kurum yönetimine devasa bir katma değer sağlayacaktır:

- **Proaktif Eğitim Anlayışı:** Öğretmenler ve idareciler, sınavlar henüz yapılmadan aylar önce hangi öğrencilerin başarısızlık riski taşıdığını ekranda görebilecek ve "sınavdan sonra not verme" yaklaşımından "sınavdan önce öğrenciyi kurtarma" vizyonuna geçiş yapılacaktır.
- **Bütçe ve Kaynak Optimizasyonu:** Okulların psikolojik danışmanlık, rehberlik ve ek etüt kaynakları rastgele değil, nokta atışı olarak modelin "Riskli (0)" tahmin ettiği hedef kitleye harcanarak verimlilik maksimize edilecektir.
- **Şeffaf Veli İletişimi:** Ailelere sadece "öğrenciniz başarısız" demek yerine, modelin arka planındaki verilere dayanarak başarısızlığın kök nedenleri (Örn: düşük motivasyon veya yetersiz uyku) veriye dayalı raporlarla sunulabilecektir.

Yapay Zeka Kullanımı

Bu projenin temel problem tanımının yapılması, veri setinin seçilmesi ve analizi, uygulanacak makine öğrenmesi mimarilerinin (algoritmaların, GridSearch kurgusunun, Cross-Validation adımlarının) tasarlanması ve sonuçların Bias-Variance, Confusion Matrix gibi konseptler ışığında bilimsel olarak yorumlanması tamamen şahsıma aittir.

Projenin teknik uygulama aşamalarında; Python (Spyder) ortamında alınan uyarı ve hataların (debug) hızlıca giderilmesi, EDA grafiklerinin görsel kalitesinin artırılması ve yazılan bu raporun akademik standartlara uygun, pürüzsüz bir LaTeX dizgisine kavuşturulması (kodlama) süreçlerinde, yapay zeka dil modellerinden (LLM) "yardımcı teknik asistan" olarak faydalanılmıştır.